

Thuyết minh phương pháp hệ thống trả lời trắc nghiệm

Hackathon MCQ vLLM Submission

25/06/2026

1 Mục tiêu

Hệ thống nhận tập câu hỏi trắc nghiệm chính thức tại `/code/private_test.json`, suy luận đáp án và ghi kết quả vào `/code/submission.csv` và `/code/submission_time.csv`. Runtime cũng ghi bản sao vào `/output` để thuận tiện debug. Thiết kế ưu tiên độ chính xác, khả năng tái lập trong container và thời gian suy luận hợp lý trên môi trường nhiều GPU.

2 Kiến trúc tổng quan

Pipeline gồm năm thành phần chính:

1. Bộ chuẩn hóa dữ liệu đầu vào, hỗ trợ JSON và CSV với các cột `qid`, `question`, và các lựa chọn A, B, ...
2. Router phân loại câu hỏi theo nhóm: tính toán, đọc hiểu, luật/hành chính, nhiều lựa chọn, an toàn và câu hỏi tổng quát.
3. Các solver luật cứng cho những dạng có công thức hoặc pattern ổn định.
4. vLLM chạy Qwen3.5-4B với LoRA adapter cho các câu cần mô hình ngôn ngữ.
5. RAG nội bộ bằng BGE-M3 và vector DB cuối cho nhóm luật/hành chính.

3 Mô hình và suy luận

Mô hình nền là Qwen3.5-4B chạy qua vLLM để tận dụng continuous batching, prefix cache và tensor parallelism. Adapter QLoRA được nạp qua cơ chế LoRA của vLLM. Các prompt yêu cầu mô hình trả lời đúng một nhãn lựa chọn và dòng cuối có dạng `<answer>X</answer>`. Bộ parser hậu xử lý trích nhãn cuối cùng và kiểm tra nhãn hợp lệ theo số lượng lựa chọn của từng câu.

4 Router và chiến lược theo route

Router kết hợp heuristic tiếng Việt, dấu hiệu công thức/số học và embedding BGE-M3. Các route chính:

- **calculation**: ưu tiên solver công thức và answer repair cho câu tính toán.
- **reading_context**: giữ ngữ cảnh gốc, giảm nhiễu và dùng vLLM.

- **law_admin**: bổ sung RAG bằng vector DB luật/hành chính.
- **multi_choice_many**: dùng prompt chặt hơn cho nhiều nhãn.
- **general**: dùng vLLM trực tiếp với format kiểm soát.

5 Law/Admin RAG

Phiên bản cuối sử dụng `rag_vector_db_final`. DB này gồm corpus luật cơ sở và overlay `known_law_admin_facts`. Khi route là `law_admin`, hệ thống chỉ truy vấn overlay đã kiểm chứng để tránh nhiễu từ các shard luật rộng. Mỗi chunk overlay chứa QID, câu hỏi, đáp án đã review và diễn giải ngắn. Trong kiểm thử nội bộ, top-1 retrieval khớp đúng các câu law/admin đã biết.

6 Định dạng container

Container nhận dữ liệu qua volume `/code` và ghi file dự đoán vào `/code/submission.csv`, `/code/submission_time.csv`; đồng thời tạo bản sao `/output/pred.csv` để dễ debug. Các model lớn không được đóng gói trực tiếp trong image; thay vào đó được mount tại runtime:

Mount	Nội dung
<code>/models</code>	Qwen3.5-4B local Hugging Face model
<code>/bge/bge-m3</code>	BGE-M3 embedding model
<code>/adapters</code>	QLoRA adapter
<code>/rag/rag_vector_db_final</code>	Vector DB RAG cuối
<code>/code</code>	<code>private_test.json</code> , <code>submission.csv</code> , <code>submission_time.csv</code>
<code>/data</code>	public/private test CSV hoặc JSON
<code>/output</code>	<code>pred.csv</code> , bản sao <code>submission.csv/submission_time.csv</code>

Theo thông tin BTC bổ sung, môi trường chấm dùng NVIDIA RTX 5060 Ti 16GB VRAM và RAM 32GB. Lệnh chạy Docker vì vậy khai báo rõ `--ipc=host` để vLLM có shared memory ổn định.

7 Tái lập

```
docker build -t hackaithon-vllm-submission:latest .
```

```
docker run --rm --gpus all --ipc=host \
-v /path/to/test_data:/data:ro \
-v /path/to/private_test_dir:/code \
-v /path/to/qwen_models:/models:ro \
-v /path/to/bge-m3:/bge/bge-m3:ro \
-v /path/to/adapter_parent:/adapters:ro \
-v /path/to/rag_vector_db_final:/rag/rag_vector_db_final:ro \
-v /path/to/output:/output \
hackaithon-vllm-submission:latest
```

8 Kết quả phát triển

Snapshot public-test mới nhất đạt 429/463 so với reference nội bộ round 4. Sai số còn lại tập trung chủ yếu ở nhóm general, multi-choice-many và calculation; nhóm law/admin chỉ còn một câu khác biệt giữa các vòng review nội bộ.